统计软件 HW9

邵智轩 1400012141 物理学院

```
HLM.url <- "http://www.xiexingcun.net/hongloumeng/"</pre>
index.url <- paste(HLM.url, "index.html", sep = "")</pre>
chapters.url <- paste(HLM.url, c(formatC(1:9, width = 2, flag = 0), 10:120),
    ".htm", sep = "")
outfcon <- file("hongloumeng.txt", open = "wt") # 输出的 txt 文件
chchar.substr <- function(c) {</pre>
    # 找出汉字子串
    find. Chinese \leftarrow \text{gregexpr}("[^\x00-\xff]|[,!?:;]", c, perl = TRUE)[[1]]
    substr(c, start = find.Chinese[1], stop = find.Chinese[length(find.Chinese)])
}
subpunc <- function(c) {</pre>
    # 替换标点符号
    c <- gsub("&quot;", "\"", c, fixed = T)</pre>
    c <- gsub("[;]?&lt;*[]?", "<", c, perl = T)
    c <- gsub("[;]?&gt;*[]?", ">", c, perl = T)
    С
}
# 利用 index 页制作 txt 的 Contents 页
makeContents <- function(index.url = index.url) {</pre>
```

```
index.text <- readLines(url(index.url))</pre>
    Contents <- grep("\\d+[.]htm", index.text, perl = TRUE, value = TRUE)</pre>
    Contents <- vapply(Contents, chchar.substr, "s")</pre>
    Contents <- c(" 红楼梦", " 清 曹雪芹 著", Contents)
    Contents
}
# 读取单章
addChapter <- function(chapter.url) {</pre>
    chapter <- readLines(url(chapter.url))</pre>
    # 找出含汉字的行
    chchar <- grep("[^\\x00-\\xff]", chapter, perl = TRUE, value = TRUE)</pre>
    # 去掉汉字行中不需要的行
    chchar <- chchar[-grep("<title>|htm| 作者: 曹雪芹", chchar, perl = TRUE)]
    # chchar<-vapply(chchar, chchar. substr, 's') 先处理标题第几回和题目
    chapnum <- chchar.substr(chchar[1])</pre>
    chapname <- chchar.substr(chchar[2])</pre>
    # 删掉回目, 下面处理正文
    chchar <- chchar[-(1:2)]</pre>
    # 没有或或<br>的段落连接到上一行
    newlines.index <- grep(" ", chchar, perl = TRUE) # 重启一行的
    chchar <- vapply(chchar, chchar.substr, "s")</pre>
    chnew <- c()
    for (i in (1:length(chchar))) {
        if (i %in% newlines.index) {
            chnew <- c(chnew, chchar[i])</pre>
        } else {
            chnew[length(chnew)] <- paste(chnew[length(chnew)], chchar[i], sep = "")</pre>
        }
    }
```

```
# 替换掉标点符号
    chnew <- subpunc(chnew)</pre>
    # 加上回目,以及回目和正文间的空行
   c("", chapnum, chapname, "", chnew)
}
time.start <- proc.time()</pre>
writeLines(makeContents(index.url), con = outfcon)
for (chapter.url in chapters.url) {
    writeLines(addChapter(chapter.url), con = outfcon)
}
proc.time() - time.start
##
     user system elapsed
             2.78
##
      9.53
                   18.07
close(outfcon)
```

效果图:

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

文件() 編輯() 格式(o) 查看(o) 帮助(h) 《 众小厮见他太撒野了,只得上来几个,揪翻捆倒,拖往马圈里去。焦大越发连贾珍都说出来,乱嚷乱叫说:"我冬要往祠堂里哭太爷去。那里承望到如今生下这些畜牲来!每日家偷狗戏鸡,爬灰的爬灰,养小叔子的养小叔子,我什么不知道?咱们 胳膊折了往袖子里藏'!"众小厮听他说出这些没天日的话来,唬的魂飞魄散,也不顾别的了,便把他捆起来,用土和马粪满满的填了他一嘴。 凤姐和贾蓉等也遥遥的闻得,便都装作没听见。宝玉在车上见这般醉闹,倒也有趣,因问风姐道:"姐姐,你听他说,爬灰的爬灰',什么是,爬灰'?"凤姐听了,连忙立眉嗔目断喝道:;少胡说!那是醉汉嘴里混吣,你是什么样的人,不说没听见,还倒细问!等我回去回了太太,仔细捶你不捶你!"唬的宝玉忙央告道:"好姐姐,我再不敢了。"凤姐道:;这才是呢。等到了家,咱们回了老太太,打发你同秦家侄儿学里念书去要紧。"说着,却自回往荣府而来。正是: 正是: 不因俊俏难为友,正为风流始读书。

第八回 比通灵金莺微露意 探宝钗黛玉半含酸

话说风姐和宝玉回家,见过众人。宝玉先便回明贾母秦钟要上家塾之事,自己也有了个伴读的朋友,正好发奋,又着实的称赞秦钟的人品行事,最使人怜爱。凤姐又在一旁帮着说"过日他还来拜老祖宗"等语,说的贾母喜欢起来。凤姐又趁势请贾母后日过去看戏。贾母虽年老,却极有兴头。至后日,又有尤氏来请,遂携了王夫人林黛玉宝玉等过去看戏。至晌午,贾母便回来歇息了。王夫人本是好清净的,见贾母回来也就回来了。然后凤姐坐了首席,尽欢至晚无话。